

Progetto di Architettura Dati

Come gli errori nei dataset di training impattano le performance dei modelli di Machine Learning

Anno Accademico 2024-2025

Relazione a cura di:

Oleksandra Golub

Matricola:

856706

Sommario

1. Introduzione	5
1.1 Contesto e motivazione	5
1.2 Obiettivi del progetto	5
1.3 Scelta del dataset e baseline	6
1.3.1. Caratteristiche del dataset	6
1.3.2. Descrizione delle feature.....	6
1.3.3. Baseline sperimentale.....	7
2. Background teorico.....	8
2.1 Concetti di Data Quality.....	8
2.2 Data Management per ML	8
2.3 Metriche di valutazione della robustezza	9
3. Metodologia	11
3.1 Struttura del progetto	11
3.2 Tipologie di errori introdotti	11
3.3 Pipeline sperimentale	12
4. Risultati sperimentali	14
4.1 Baseline (Fase 1)	14
4.1.1 Presentazione dei risultati	15
4.1.2 Riepilogo dei risultati.....	18
4.2 Effetti degli errori singoli (Fase 2 – Parte I)	19
4.2.1 Label Noise.....	19
4.2.1.1 Matrici di confusione per diversi livelli di rumore	20
4.2.1.2 Andamento delle performance al variare del livello di rumore	22
.....	24
4.2.1.3 Confronto delle metriche per modello e livello di rumore	24
4.2.1.4 Curve ROC per diversi livelli di rumore	28
4.2.1.5 Riepilogo dei risultati.....	31
4.2.2 Feature Noise	31
4.2.2.1 Matrici di confusione per diversi livelli di rumore	32
4.2.2.2 Andamento delle performance al variare del livello di rumore	34
4.2.2.3 Confronto delle metriche per modello e livello di rumore	37
4.2.2.4 Curve ROC per diversi livelli di rumore	41
4.2.2.5 Riepilogo dei risultati.....	43
4.2.3 Missing Values	43
4.2.3.1 Matrici di confusione per diversi livelli di rumore	44
4.2.3.2 Andamento delle performance al variare del livello di rumore	46

.....	48
4.2.3.3 Confronto delle metriche per modello e livello di rumore	48
4.2.3.4 Curve ROC per diversi livelli di rumore	52
4.2.3.5 Riepilogo dei risultati.....	55
4.2.4 Feature Outliers	55
4.2.4.1 Matrici di confusione per diversi livelli di rumore.....	56
4.2.4.2 Andamento delle performance al variare del livello di rumore	58
4.2.4.3 Confronto delle metriche per modello e livello di rumore	60
4.2.4.4 Curve ROC per diversi livelli di outlier	64
4.2.4.5 Riepilogo dei risultati.....	66
4.2.5 Duplicates Features	66
4.2.5.1 Matrici di confusione per diversi livelli di rumore	67
4.2.5.2 Andamento delle performance al variare del livello di rumore	69
4.2.5.3 Confronto delle metriche per modello e livello di rumore	71
4.2.5.4 Curve ROC per diversi livelli di duplicati.....	75
4.2.5.5 Riepilogo dei risultati.....	78
4.3 Effetti degli errori combinati (Fase 2 – Parte II)	79
4.3.1 Label Noise + Feature Noise	80
4.3.1.1 Matrici di confusione.....	80
4.3.1.2 Andamento delle performance al variare del livello di rumore.....	83
4.3.1.3 Confronto delle metriche per modello e livello di rumore	86
4.3.1.4 Curve ROC per diversi livelli di duplicati.....	90
4.3.1.5 Riepilogo dei risultati.....	92
4.3.2 Label Noise + Missing Values.....	93
4.3.2.1 Matrici di confusione.....	93
4.3.2.3 Andamento delle performance al variare del livello di rumore	96
4.3.2.3 Confronto delle metriche per modello e livello di rumore	99
4.3.2.4 Curve ROC per diversi livelli di duplicati.....	103
4.3.2.5 Riepilogo dei risultati.....	105
4.3.3 Feature Noise + Feature Outliers	106
4.3.3.1 Matrici di confusione.....	106
4.3.3.3 Andamento delle performance al variare del livello di rumore	109
4.3.3.3 Confronto delle metriche per modello e livello di rumore	112
4.3.3.4 Curve ROC per diversi livelli di duplicati.....	116
4.3.3.5 Riepilogo dei risultati.....	118
4.3.4 Duplicates Features + Feature Noise	118

4.3.4.1 Matrici di confusione.....	119
4.3.4.3 Andamento delle performance al variare del livello di rumore	121
4.3.4.3 Confronto delle metriche per modello e livello di rumore	124
4.3.4.4 Curve ROC per diversi livelli di duplicati.....	128
4.3.4.5 Riepilogo dei risultati.....	130
4.4 Robustezza dei modelli.....	131
5. Conclusioni	135
5.1 Natura dei modelli	135

1. Introduzione

Questo progetto analizza come errori e contaminazioni nei dataset di training possano influenzare le prestazioni dei modelli di Machine Learning. A partire da un dataset clinico sul diabete, vengono introdotti diversi tipi di rumore artificiale e valutati gli effetti su vari algoritmi di classificazione.

1.1 Contesto e motivazione

La qualità dei dati rappresenta un aspetto fondamentale in ogni processo di analisi e, in particolare, nello sviluppo di modelli di Machine Learning. Un modello addestrato su dati incompleti, inaccurati o incoerenti rischia infatti di produrre risultati fuorvianti o poco affidabili, con conseguenze dirette sull'efficacia delle decisioni basate sulle sue previsioni.

Come discusso nel corso di Architetture Dati, la qualità dei dati può essere descritta lungo diverse dimensioni (**accuratezza, completezza, consistenza, tempestività**) e il loro controllo è essenziale per garantire buone prestazioni nei sistemi informativi e negli algoritmi di apprendimento.

Nel caso del Machine Learning, il problema si amplifica perché i modelli apprendono direttamente dai dati disponibili: eventuali errori presenti nei dataset di training si riflettono in maniera sistematica sulle performance, introducendo **bias**, riducendo la capacità di generalizzazione e compromettendo la robustezza del modello. Inoltre, come mostrato nel materiale del corso Use Case Machine Learning, la pipeline di addestramento e validazione deve prevedere controlli continui sulla qualità dei dati, poiché anomalie o alterazioni possono propagarsi fino al deployment, con conseguenze critiche in scenari reali.

1.2 Obiettivi del progetto

Lo scopo di questo progetto è analizzare come la presenza di errori nei dati di addestramento influenzi le prestazioni dei modelli di apprendimento automatico. In particolare:

- introdurre in maniera controllata differenti forme di contaminazione dei dati (rumore nelle feature numeriche, valori mancanti, etichette errate, outlier e duplicazioni);
- osservare quantitativamente e qualitativamente come queste alterazioni si riflettano sulle metriche di valutazione (accuracy, precision, recall, F1-score, ROC-AUC);

- confrontare il comportamento di diversi algoritmi di classificazione (Decision Tree, Random Forest, Support Vector Machine e Multilayer Perceptron) al variare dell'intensità e della tipologia di errore;
- identificare quali modelli risultano più robusti in funzione della contaminazione, discutendo le possibili motivazioni alla luce delle caratteristiche degli algoritmi.

L'analisi non si limita quindi a misurare il degrado delle prestazioni, ma mira anche a fornire indicazioni pratiche su come la qualità dei dati condizioni l'affidabilità dei modelli e quali compromessi possano essere accettabili in scenari applicativi reali.

1.3 Scelta del dataset e baseline

Per lo studio è stato utilizzato un dataset pubblico disponibile su **Kaggle**, contenente informazioni cliniche relative a pazienti diabetici e non diabetici.

1.3.1. Caratteristiche del dataset

- **Tipologia:** multivariato
- **Numero di istanze:** 768
- **Numero di attributi:** 9
- **Caratteristiche degli attributi:** numerici continui o discreti
- **Valori errati e/o anomali:** presenti in alcune variabili, da gestire nel preprocessing

1.3.2. Descrizione delle feature

- **Pregnancies:** numero di gravidanze precedenti del paziente
- **Glucose:** livello di glucosio plasmatico a 2 ore dal test di tolleranza al glucosio
- **BloodPressure:** pressione sanguigna diastolica
- **SkinThickness:** spessore della pelle, indicatore della resistenza all'insulina
- **Insulin:** livello di insulina nel sangue
- **BMI:** indice di massa corporea
- **Diabetes Pedigree Function (DPF):** indice che riflette la predisposizione genetica al diabete
- **Age:** età della paziente
- **Outcome:** variabile target (1 = diabetico, 0 = non diabetico)

1.3.3. Baseline sperimentale

Il punto di partenza dell'analisi è rappresentato da una **fase baseline (fase 1)**, in cui i modelli sono stati addestrati e valutati su dati “puliti”, ovvero privi di contaminazioni artificiali. Questa fase iniziale consente di stabilire un riferimento oggettivo delle performance massime ottenibili con dati corretti, rispetto al quale confrontare i risultati derivanti dall'introduzione di errori.

Successivamente, nella **fase 2**, i dati sono stati contaminati progressivamente introducendo diversi tipi di rumore, sia singolarmente che in combinazione, con l'obiettivo di simulare scenari realistici di degrado della qualità dei dati e analizzarne le conseguenze sulle prestazioni dei modelli.

2. Background teorico

2.1 Concetti di Data Quality

La qualità dei dati è un concetto multidimensionale che descrive quanto un dataset sia adeguato allo scopo per cui viene utilizzato. Nel corso di Architetture Dati sono state evidenziate alcune dimensioni fondamentali:

- **Accuracy (Accuratezza):** misura la correttezza dei valori rispetto alla realtà. Un dato accurato è privo di errori di digitazione, sensori difettosi o etichette sbagliate.
- **Completeness (Completezza):** indica la presenza o meno di tutti i dati necessari. Valori mancanti o campi incompleti riducono la capacità di un modello di apprendere correttamente.
- **Consistency (Consistenza):** riguarda la coerenza interna dei dati. Ad esempio, una stessa entità non dovrebbe presentare valori diversi in campi che dovrebbero coincidere.
- **Currency (Tempestività o attualità):** rappresenta quanto i dati siano aggiornati e riflettano la situazione reale nel momento di utilizzo.

Queste dimensioni spesso comportano **trade-off**. Ad esempio, garantire la **tempestività** dei dati può ridurre l'**accuratezza** se non vi è tempo per controlli di qualità approfonditi. Al contrario, procedure di verifica estese aumentano l'accuratezza, ma introducono ritardi nell'accesso ai dati.

Le strategie per migliorare la qualità possono essere:

- **Data-driven**, focalizzate sulla pulizia e trasformazione dei dati già raccolti (es. deduplicazione, imputazione di valori mancanti, normalizzazione).
- **Process-driven**, orientate a prevenire gli errori intervenendo sul processo di raccolta, gestione e inserimento dei dati, garantendo che le fonti siano affidabili fin dall'inizio.

2.2 Data Management per ML

L'apprendimento automatico è fortemente dipendente dalla qualità dei dati, poiché i modelli apprendono schemi direttamente dai dataset di addestramento. Una pipeline di Machine Learning, come discusso nelle lezioni, comprende tipicamente le seguenti fasi:

1. **Data Understanding** – analisi preliminare per comprendere struttura, distribuzioni e possibili anomalie.
2. **Data Validation** – verifica che i dati rispettino vincoli formali (schema, domini, integrità).
3. **Data Preparation** – trasformazioni necessarie all’addestramento (scaling, encoding, imputazione, riduzione della dimensionalità).
4. **Data Fixing** – correzione degli errori individuati (gestione outlier, rimozione duplicati, ricostruzione di valori mancanti).

Un problema critico in questo contesto è lo **skew tra training e serving**, cioè la differenza tra i dati usati per addestrare il modello e quelli incontrati in fase di utilizzo reale. Tale disallineamento può portare a un degrado delle performance, anche quando i dati di training sono stati puliti. Per questo motivo, oltre alla validazione iniziale, è fondamentale attuare un **monitoraggio continuo dei dati in input** durante la fase di produzione, al fine di rilevare anomalie e adottare strategie di correzione.

2.3 Metriche di valutazione della robustezza

La valutazione dei modelli di Machine Learning avviene tradizionalmente tramite metriche di classificazione:

- **Accuracy:** proporzione di esempi classificati correttamente.
- **Precision e Recall:** misurano rispettivamente l’assenza di falsi positivi e la capacità di catturare i veri positivi.
- **F1-score:** media armonica di precision e recall, utile in caso di dataset sbilanciati.
- **ROC-AUC:** misura la capacità discriminativa del modello indipendentemente dalla soglia di classificazione.

Tuttavia, quando l’obiettivo è valutare la **robustezza dei modelli rispetto a dati degradati**, è necessario osservare non solo le prestazioni assolute, ma anche **come queste variano al crescere del livello di errore introdotto**. A questo scopo, nel corso è stata discussa la metrica **EPC (Error-Performance Correlation)**, che quantifica la correlazione tra la percentuale di errori presenti nei dati e la degradazione delle performance del modello.

L’EPC permette di misurare la sensibilità del modello rispetto a diverse tipologie di contaminazione: un valore elevato di correlazione indica che piccoli incrementi negli

errori portano a forti cali nelle performance, mentre valori bassi suggeriscono una maggiore robustezza del modello.

3. Metodologia

3.1 Struttura del progetto

Il progetto è stato articolato in due fasi principali:

- **Fase 1 – Baseline con dati puliti**

In questa fase i modelli di Machine Learning sono stati addestrati e valutati utilizzando il dataset originale, privo di contaminazioni artificiali. L'obiettivo era ottenere un punto di riferimento stabile (baseline) per le performance, da utilizzare come termine di confronto con gli esperimenti successivi.

- **Fase 2 – Introduzione di errori nei dati**

La seconda fase ha previsto l'inserimento controllato di errori all'interno del dataset di training, al fine di simulare scenari realistici di degradazione della qualità dei dati. Questa fase è stata a sua volta suddivisa in due parti:

- **Parte I – Errori singoli:** analisi dell'impatto di ciascun tipo di errore considerato (label noise, feature noise, missing values, outlier, duplicati).
- **Parte II – Errori combinati:** valutazione dell'effetto di più errori presenti contemporaneamente nello stesso dataset (ad esempio: label noise + feature noise).

Questa struttura sperimentale consente sia di isolare l'effetto di ciascun tipo di errore, sia di analizzare interazioni e sinergie negative quando diversi errori si combinano.

3.2 Tipologie di errori introdotti

Sono state considerate diverse forme di “contaminazione” dei dati, scelte in base alla loro frequenza e rilevanza nei contesti reali:

- **Label Noise (rumore nelle etichette)**

Alterazione casuale delle classi nel dataset di training. È un errore critico perché compromette direttamente l'apprendimento supervisionato, inducendo il modello a generalizzare regole scorrette.

- **Feature Noise (rumore nelle feature)**

Introduzione di rumore gaussiano nei valori numerici delle variabili. Simula errori di misurazione da parte di sensori o inserimenti manuali, che portano a uno “sfocamento” delle distribuzioni delle feature.

- **Missing Values (valori mancanti)**

Eliminazione di valori in alcune celle del dataset. Questa forma di incompletezza

è estremamente comune in ambito clinico e può alterare i pattern che il modello è in grado di apprendere.

- **Outliers (valori anomali)**

Inserimento di valori estremi nelle feature numeriche. Anche pochi outlier possono influenzare in modo significativo modelli non robusti, spostando confini di decisione o media statistica.

- **Duplicati**

Inserimento artificiale di righe duplicate. Questo errore introduce ridondanza e bias nel dataset, con il rischio di far “pesare di più” alcuni esempi rispetto ad altri.

- **Errori combinati**

Oltre agli errori singoli, sono stati testati scenari con combinazioni di contaminazioni, come ad esempio:

- Label noise + feature noise;
- Label noise + missing values;
- Feature noise + outlier;
- Feature noise + duplicati.

Queste combinazioni simulano contesti più complessi e realistici, nei quali la qualità dei dati risente di più fattori contemporaneamente.

3.3 Pipeline sperimentale

L'intero flusso di lavoro è stato sviluppato in **Python** e implementato su **Google Colab** per garantire riproducibilità e scalabilità. Le principali librerie utilizzate sono state:

- **scikit-learn (sklearn)**: per l'implementazione dei modelli di classificazione e delle metriche di valutazione.
- **imbalanced-learn (imblearn)**: per la gestione degli sbilanciamenti di classe, tramite tecniche come **SMOTE**.
- **pandas e numpy**: per la manipolazione dei dataset.

I modelli testati appartengono a diverse famiglie di algoritmi di classificazione:

- **Decision Tree (DT)**: interpretabile ma sensibile al rumore.
- **Random Forest (RF)**: più robusto, grazie alla combinazione di alberi multipli.

- **Support Vector Machine (SVM):** efficace in spazi ad alta dimensionalità, ma sensibile al label noise.
- **Multilayer Perceptron (MLP):** rete neurale a più strati, in grado di catturare pattern complessi ma potenzialmente vulnerabile a dati rumorosi.

Per garantire risultati significativi sono state adottate le seguenti tecniche:

- **SMOTE (Synthetic Minority Oversampling Technique):** per gestire l'eventuale sbilanciamento tra classi.
- **Scaling delle feature:** per normalizzare le variabili numeriche e permettere un corretto funzionamento di algoritmi sensibili alle scale (SVM, MLP).
- **Validazione incrociata (cross-validation):** per ridurre il rischio di overfitting e ottenere stime robuste delle performance dei modelli.

4. Risultati sperimentali

4.1 Baseline (Fase 1)

Come punto di riferimento iniziale, i modelli sono stati addestrati e valutati sul dataset originale, privo di contaminazioni artificiali. Questa fase ha permesso di stabilire la baseline delle performance, utile per misurare il degrado causato dagli errori introdotti successivamente.

Le metriche principali calcolate (accuracy, precision, recall, F1-score, AUC) hanno mostrato che:

- **Random Forest** ha ottenuto le migliori prestazioni complessive, con valori di precisione fino all'87.65% e l'AUC più elevato (0.9509). Questo indica un'ottima capacità discriminante tra pazienti sani e diabetici, oltre a una buona stabilità come evidenziato dagli intervalli di confidenza.
- **SVM** ha raggiunto risultati molto vicini a Random Forest, con AUC pari a 0.9311 e metriche comprese tra l'87.1% e l'87.5%. È un modello competitivo che bilancia accuratezza ed efficienza computazionale, distinguendosi anche per tempi di addestramento contenuti.
- **MLP** ha mostrato un'AUC pari a 0.9392 e metriche solide (86.5–86.9%). Le sue prestazioni sono comparabili a SVM e RF, ma i tempi di training risultano significativamente più alti, rendendolo meno efficiente dal punto di vista computazionale.
- **Decision Tree** ha ottenuto i valori più bassi, con accuracy attorno all'83% e AUC pari a 0.9125. Pur essendo meno performante, si conferma molto rapido nell'addestramento e facilmente interpretabile, caratteristiche utili in scenari con risorse limitate o necessità di explainability.

In sintesi, **Random Forest emerge come il modello migliore in fase baseline**, seguito a breve distanza da SVM e MLP. Il Decision Tree resta invece una soluzione più semplice e interpretabile, ma meno accurata.

4.1.1 Presentazione dei risultati

Di seguito vengono riportati i principali grafici di supporto relativi alla fase baseline:

a) Confronto delle metriche principali (Accuracy, Precision, Recall, F1-score):




Figura 1 – Confronto delle metriche di performance tra i modelli

Dalla Figura 1 si nota come Random Forest, SVM e MLP ottengano prestazioni molto vicine, con valori compresi tra l'86% e l'87%, mentre il Decision Tree risulta distanziato, fermandosi attorno all'83%.

b) Capacità discriminante (ROC-AUC):




Figura 2 – Curve ROC dei modelli

La Figura 2 evidenzia la capacità discriminante dei modelli: il Random Forest ottiene il valore più alto di AUC (0.9509), seguito da MLP (0.9392) e SVM (0.9311). Il Decision Tree rimane il meno performante, pur mantenendosi sopra la soglia della classificazione casuale (AUC = 0.9125).

c) Stabilità delle prestazioni:




Figura 3 – Intervalli di confidenza al 95% delle metriche

La Figura 3 mostra la variabilità delle metriche: Random Forest e SVM presentano gli intervalli di confidenza più stretti, indicando una maggiore stabilità dei risultati. L'MLP mantiene una buona coerenza, ma con intervalli leggermente più ampi, mentre il Decision Tree evidenzia la maggiore variabilità.

d) Tempi di training:




Figura 4 – Tempi di addestramento comparati

La Figura 4 conferma che il Decision Tree è nettamente il più veloce da addestrare (0.006 s), seguito da SVM (0.060 s), Random Forest (0.173 s) e infine MLP, che richiede il tempo più elevato (0.289 s). Questo aspetto sottolinea l'importanza di considerare anche il costo computazionale nella scelta del modello.

4.1.2 Riepilogo dei risultati

In sintesi, le Figure 1–4 mostrano come il **Random Forest** emerga come il modello migliore in fase baseline, combinando accuratezza, capacità discriminante e stabilità.

La **SVM** rappresenta un'ottima alternativa, con buoni trade-off tra prestazioni e tempi di training. L'**MLP** raggiunge risultati solidi ma a costo computazionale più alto, mentre il **Decision Tree** resta la soluzione più rapida e interpretabile, seppur meno accurata.

4.2 Effetti degli errori singoli (Fase 2 – Parte I)

Dopo aver definito la baseline con dati puliti, nella seconda fase dell'esperimento i dataset sono stati **contaminati introducendo un singolo tipo di errore alla volta**, al fine di valutare l'effetto isolato di ciascuna fonte di degrado sulla qualità dei modelli.

Per garantire coerenza e confrontabilità, la **pipeline sperimentale** è stata mantenuta costante in tutte le prove:

- preprocessing con imputazione e scaling,
- bilanciamento delle classi tramite SMOTE,
- addestramento dei modelli con gli stessi iperparametri ottimizzati,
- valutazione mediante validazione incrociata stratificata,
- misurazione delle performance con accuracy, precision, recall, F1-score e AUC.

Ogni tipo di errore è stato introdotto in maniera **progressiva**, simulando diversi livelli di intensità. In particolare, sono state testate percentuali crescenti di contaminazione pari al **10%, 20%, 30%, 40% e 50%** in modo da osservare l'andamento delle metriche al crescere della degradazione dei dati.

L'obiettivo di questa fase è duplice:

1. **Quantificare la sensibilità di ciascun modello** rispetto a una specifica forma di errore, evidenziando quali algoritmi risultino più vulnerabili.
2. **Identificare i modelli più robusti**, cioè quelli in grado di mantenere prestazioni accettabili anche in presenza di dati alterati.

Questa analisi consente di comprendere meglio le caratteristiche intrinseche degli algoritmi e di valutare la loro affidabilità in scenari reali, dove errori di misura, etichette errate o anomalie nei dati sono inevitabili.

4.2.1 Label Noise


Il **label noise** rappresenta una delle forme più critiche di contaminazione nei dataset, in quanto altera direttamente la variabile target, compromettendo il processo di apprendimento supervisionato. In questo esperimento, una percentuale delle etichette è stata invertita in modo casuale (ad esempio trasformando alcuni pazienti sani in diabetici e viceversa), mantenendo costanti tutte le altre componenti della pipeline.


Sono stati considerati diversi livelli di rumore, per valutare come la progressiva introduzione di errori nelle etichette influenzi le performance dei modelli.

4.2.1.1 Matrici di confusione per diversi livelli di rumore

Le matrici di confusione mostrano come il rumore porti ad una **maggiore confusione tra classi sane e diabetiche**:

- Con livelli bassi (10–20%), gli errori si concentrano solo in alcune predizioni.
- Oltre il 30%, i falsi positivi e falsi negativi aumentano drasticamente, riducendo la capacità predittiva complessiva.





4.2.1.2 Andamento delle performance al variare del livello di rumore


Dai grafici di **accuracy**, **precision**, **recall** e **F1-score** emerge un chiaro trend di degrado progressivo:

- **MLP** è risultato il modello più sensibile: già al 20% di rumore le performance calano drasticamente, fino a valori molto bassi oltre il 40–50%.
- **SVM** e **Random Forest** hanno mantenuto prestazioni accettabili fino al 20% di rumore, ma mostrano un crollo significativo oltre il 30%.
- **Decision Tree** si è dimostrato relativamente più stabile nelle prime fasi, ma anche in questo caso, oltre il 40% di rumore, le metriche collassano.




	DecisionTree	MLP	RandomForest	SVM
0%	0.888	0.871	0.862	0.897
10%	0.836	0.819	0.879	0.853
20%	0.862	0.733	0.871	0.853
30%	0.716	0.655	0.819	0.819
40%	0.741	0.612	0.638	0.69
50%	0.638	0.474	0.543	0.638

Precision vs Livello di Rumore




	DecisionTree	MLP	RandomForest	SVM
0%	0.912	0.842	0.857	0.872
10%	0.712	0.717	0.865	0.833
20%	0.838	0.6	0.783	0.75
30%	0.562	0.509	0.75	0.7
40%	0.789	0.457	0.49	0.553
50%	0.486	0.321	0.385	0.486

Recall vs Livello di Rumore






	DecisionTree	MLP	RandomForest	SVM
0%	0.827	0.81	0.789	0.85
10%	0.796	0.759	0.821	0.779
20%	0.795	0.659	0.828	0.809
30%	0.686	0.574	0.741	0.769
40%	0.5	0.483	0.543	0.591
50%	0.447	0.371	0.43	0.462







	DecisionTree	MLP	RandomForest	SVM
0%	0.756	0.78	0.732	0.829
10%	0.902	0.805	0.78	0.732
20%	0.756	0.732	0.878	0.878
30%	0.878	0.659	0.732	0.854
40%	0.366	0.512	0.61	0.634
50%	0.415	0.439	0.488	0.439


4.2.1.3 Confronto delle metriche per modello e livello di rumore















4.2.1.4 Curve ROC per diversi livelli di rumore

Le curve ROC confermano questi risultati:

- In assenza di rumore (0%), tutti i modelli mostrano $AUC > 0.90$, con Random Forest e SVM vicini a 0.95.
- Già al 30% di rumore l'AUC inizia a calare sensibilmente (es. MLP da 0.93 $\rightarrow$ 0.68).
- Con il 50% di rumore, le curve ROC si avvicinano alla diagonale casuale ($AUC \sim 0.55-0.60$), indicando che i modelli non riescono più a discriminare correttamente tra classi.





4.2.1.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al label noise tramite la metrica EPC:

Model	EPC
DecisionTree	-0.923
SVM	-0.941
RandomForest	-0.888
MLP	-0.989

Interpretazione:

- Tutti i modelli presentano valori **fortemente negativi**, confermando che l'aumento del rumore ha un effetto quasi lineare e devastante sulle performance.
- L'**MLP** (-0.989) è risultato il più fragile, con prestazioni che collassano rapidamente.
- La **Random Forest** (-0.888) ha mostrato la maggiore resilienza, mantenendo valori accettabili fino al 20–30% di rumore.
- **SVM** e **Decision Tree** si collocano in una posizione intermedia, con robustezza limitata ma comunque superiore all'MLP.

In sintesi, l'esperimento mostra come la presenza di etichette errate influenzi pesantemente le prestazioni, con un impatto differenziato tra i modelli: **più contenuto per Random Forest, devastante per MLP**.

Questo risultato conferma la necessità di procedure di controllo e validazione delle etichette, soprattutto in contesti clinici. Nel capitolo successivo analizzeremo invece un diverso tipo di contaminazione, ovvero il rumore introdotto direttamente nelle feature numeriche.

4.2.2 Feature Noise


Il **feature noise** consiste nell'introduzione di rumore gaussiano all'interno delle variabili numeriche del dataset. Questo tipo di contaminazione non altera la variabile target, ma “sfoca” i valori delle feature, riducendo la separabilità tra le classi. Si tratta di un errore comune in contesti clinici e industriali, dove strumenti di misurazione possono restituire valori imprecisi.


Sono stati considerati diversi livelli di rumore, per valutare come la progressiva introduzione di errori influenzi le performance dei modelli.

4.2.2.1 Matrici di confusione per diversi livelli di rumore

Le matrici di confusione mostrano come il rumore porti ad una **maggiore confusione tra classi sane e diabetiche**:

- Con livelli bassi (10–20%), gli errori di classificazione sono quasi invariati rispetto alla baseline.
- A livelli più alti (40–50%), si osserva un leggero aumento dei falsi positivi/negativi, ma senza il collasso drastico visto con il label noise.







4.2.2.2 Andamento delle performance al variare del livello di rumore

Dai grafici di **accuracy**, **precision**, **recall** e **F1-score** emergono le seguenti tendenze:


- **SVM** è il modello più robusto, mantenendo performance molto stabili e addirittura migliorando leggermente con rumore moderato (20–30%).
- **MLP** mostra una buona capacità di adattamento: recall e F1-score restano elevati anche con rumore medio-alto, pur con qualche oscillazione nelle precision.
- **Random Forest** mantiene stabilità nelle performance con un leggero calo della precisione, ma senza degradazioni gravi.
- **Decision Tree** è il più sensibile: presenta oscillazioni significative (specialmente su precision e recall), evidenziando fragilità quando il rumore aumenta.




	DecisionTree	MLP	RandomForest	SVM
0%	0.888	0.871	0.862	0.897
10%	0.888	0.888	0.862	0.897
20%	0.828	0.888	0.853	0.905
30%	0.879	0.897	0.871	0.914
40%	0.879	0.871	0.871	0.905
50%	0.828	0.888	0.871	0.905



	DecisionTree	MLP	RandomForest	SVM
0%	0.912	0.842	0.857	0.872
10%	0.912	0.818	0.838	0.872
20%	0.744	0.818	0.816	0.875
30%	0.909	0.872	0.825	0.897
40%	0.909	0.861	0.825	0.857
50%	0.744	0.889	0.825	0.857





	DecisionTree	MLP	RandomForest	SVM
0%	0.756	0.78	0.732	0.829
10%	0.756	0.878	0.756	0.829
20%	0.78	0.878	0.756	0.854
30%	0.732	0.829	0.805	0.854
40%	0.732	0.756	0.805	0.878
50%	0.78	0.78	0.805	0.878




	DecisionTree	MLP	RandomForest	SVM
0%	0.827	0.81	0.789	0.85
10%	0.827	0.847	0.795	0.85
20%	0.762	0.847	0.785	0.864
30%	0.811	0.85	0.815	0.875
40%	0.811	0.805	0.815	0.867
50%	0.762	0.831	0.815	0.867


4.2.2.3 Confronto delle metriche per modello e livello di rumore




Andamento performance per SVM




Metriche per SVM per livello di rumore





Andamento performance per RandomForest



Metriche per RandomForest per livello di rumore









4.2.2.4 Curve ROC per diversi livelli di rumore

Le curve ROC evidenziano che tutti i modelli mantengono un'elevata capacità discriminante:

- AUC resta stabile intorno a 0.93–0.96 per tutti i livelli di rumore.
- L'MLP presenta leggere variazioni, ma senza un calo sistematico.
- RF e SVM rimangono costanti con $AUC \approx 0.95$, mostrando un'elevata resistenza al feature noise.





4.2.2.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al feature noise tramite la metrica EPC:

Model	EPC
DecisionTree	-0.505
SVM	0.639
RandomForest	0.655
MLP	0.218

Interpretazione:

- A differenza del label noise, l'introduzione di rumore nelle feature non ha un impatto catastrofico.
- Il **Decision Tree** (-0.505) è l'unico a mostrare una relazione negativa, evidenziando fragilità e oscillazioni nelle performance.
- **MLP** (0.218) reagisce bene al rumore e in alcuni casi migliora le metriche, probabilmente grazie a un effetto regolarizzante del noise.
- **Random Forest** (0.655) e **SVM** (0.639) emergono come i modelli più robusti, mantenendo prestazioni stabili e addirittura in lieve crescita con rumore moderato.


In sintesi, **il feature noise non degrada le performance in maniera drastica**: anzi, in **alcuni casi sembra avere un effetto neutro o persino leggermente positivo**, probabilmente perché introduce variabilità utile ad aumentare la generalizzazione del modello.

Questo contrasta nettamente con i risultati osservati nel label noise, confermando che gli algoritmi di Machine Learning sono molto più sensibili a etichette errate rispetto a imprecisioni numeriche nelle variabili di input.

4.2.3 Missing Values

L'introduzione di **valori mancanti** rappresenta un altro scenario tipico di contaminazione nei dataset clinici, derivante da errori di raccolta, omissioni nei questionari o malfunzionamenti nei dispositivi di acquisizione. In questo esperimento è stata simulata la presenza di valori mancanti sostituendo in modo casuale una percentuale delle feature con valori nulli, successivamente gestiti tramite strategie di imputazione all'interno della pipeline.


Sono stati **testati livelli crescenti di missingness** (10%, 20%, 30%, 40% e 50%) per valutare la capacità dei modelli di mantenere prestazioni accettabili in condizioni di dati incompleti.



4.2.3.2 Andamento delle performance al variare del livello di rumore


Dai grafici di **accuracy**, **precision**, **recall** e **F1-score** emergono le seguenti tendenze:

- **Decision Tree**: progressivo calo delle metriche, con stabilità solo fino al 20%, per poi degradare fortemente (F1 ~0.71 al 50%).
- **MLP**: comportamento instabile; mantiene valori discreti fino al 20–30%, ma crolla drasticamente al 50% (accuracy ~0.66, F1 ~0.53).
- **Random Forest**: modello più robusto, con un degrado più lento e valori ancora superiori a 0.80 di accuracy al 50% di missing.
- **SVM**: inizialmente molto stabile, ma subisce un peggioramento netto oltre il 30–40%, con recall particolarmente penalizzato.




	DecisionTree	MLP	RandomForest	SVM
0%	0.888	0.871	0.862	0.897
10%	0.879	0.845	0.862	0.897
20%	0.836	0.862	0.888	0.905
30%	0.819	0.784	0.862	0.819
40%	0.81	0.81	0.845	0.767
50%	0.759	0.664	0.81	0.776

Precision vs Livello di Missing Values




	DecisionTree	MLP	RandomForest	SVM
0%	0.912	0.842	0.857	0.872
10%	0.909	0.767	0.821	0.854
20%	0.729	0.791	0.818	0.841
30%	0.778	0.667	0.838	0.727
40%	0.721	0.694	0.767	0.675
50%	0.614	0.524	0.721	0.66

Recall vs Livello di Missing Values






	DecisionTree	MLP	RandomForest	SVM
0%	0.756	0.78	0.732	0.829
10%	0.732	0.805	0.78	0.854
20%	0.854	0.829	0.878	0.902
30%	0.683	0.78	0.756	0.78
40%	0.756	0.829	0.805	0.659
50%	0.854	0.537	0.756	0.756







	DecisionTree	MLP	RandomForest	SVM
0%	0.827	0.81	0.789	0.85
10%	0.811	0.786	0.8	0.854
20%	0.787	0.81	0.847	0.871
30%	0.727	0.719	0.795	0.753
40%	0.738	0.756	0.786	0.667
50%	0.714	0.53	0.738	0.705


4.2.3.3 Confronto delle metriche per modello e livello di rumore















4.2.3.4 Curve ROC per diversi livelli di rumore

Le curve ROC mostrano un progressivo avvicinamento alla diagonale casuale con l'aumento della percentuale di missing:

- In assenza di valori mancanti (0%), tutti i modelli hanno $AUC \geq 0.93$.
- Con il 30% di missingness, Decision Tree e MLP calano a valori $AUC \sim 0.82-0.83$.
- Random Forest e SVM mantengono AUC più elevati ($\sim 0.91-0.93$ al 40%), ma subiscono comunque un peggioramento significativo.
- Con il 50% di valori mancanti, MLP è il più penalizzato ($AUC 0.78$), mentre Random Forest resta il più solido ($AUC 0.91$).





4.2.3.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al feature noise tramite la metrica EPC:

Model	EPC
DecisionTree	-0.974
SVM	-0.901
RandomForest	-0.696
MLP	-0.845

Interpretazione:

- Tutti i modelli mostrano valori EPC negativi, confermando che l'aumento dei valori mancanti degrada le prestazioni.
- **Decision Tree** (-0.974) è il più vulnerabile, con metriche che collassano rapidamente oltre il 30%.
- **MLP** (-0.845) mostra una forte fragilità, soprattutto in termini di precision e F1.
- **Random Forest** (-0.696) è il modello più resiliente, mantenendo performance accettabili anche al 50%.
- **SVM** (-0.901) si colloca in una posizione intermedia: buono fino al 20%, ma sensibile a missing più elevati.

In sintesi, l'esperimento dimostra che la **gestione dei valori mancanti è cruciale per garantire robustezza** nei modelli di classificazione clinica.

Di nuovo, **la Random Forest si conferma più stabile**, mentre Decision Tree e MLP soffrono pesantemente.

4.2.4 Feature Outliers


Gli outlier sono osservazioni con **valori estremi** rispetto alla distribuzione delle feature. In ambito clinico possono derivare da errori di inserimento/misurazione, casi rari o pazienti atipici. In questo esperimento abbiamo introdotto artificialmente valori anomali in una quota di record, perturbando alcune variabili numeriche con scostamenti molto elevati (ad es. tramite aggiunta di valori a più deviazioni standard dalla media).


La pipeline (preprocessing, SMOTE, scaling, validazione e metriche) è rimasta invariata rispetto alle altre prove. Sono stati testati livelli crescenti di contaminazione (10%, 20%, 30%, 40%, 50%) per valutare la robustezza dei modelli in presenza di valori estremi.

4.2.4.1 Matrici di confusione per diversi livelli di rumore

Le matrici di confusione mostrano un andamento meno drammatico rispetto al label noise:

- **Random Forest** mantiene un buon equilibrio tra falsi positivi/negativi fino al 40%.
- **Decision Tree e MLP** risultano più instabili, con fluttuazioni significative tra i diversi livelli.
- **SVM** soffre maggiormente gli outlier, con progressivo aumento degli errori di classificazione già dal 20–30%.







4.2.4.2 Andamento delle performance al variare del livello di rumore

Dai grafici di **accuracy**, **precision**, **recall** e **F1-score** emergono le seguenti tendenze:


- **Random Forest** si conferma il modello più robusto: in alcuni casi mostra persino un leggero miglioramento fino al 40% di outlier, grazie al meccanismo di bagging che mitiga l'influenza delle anomalie.
- **Decision Tree** evidenzia un comportamento altalenante, con recall elevato al 50% ma precision in forte calo.
- **SVM** subisce un degrado progressivo, soprattutto oltre il 30%, dove recall e F1-score scendono nettamente.
- **MLP mostra instabilità**: inizialmente regge bene, ma oltre il 40% di outlier le performance collassano.



	DecisionTree	MLP	RandomForest	SVM
0%	0.888	0.871	0.862	0.897
10%	0.845	0.853	0.888	0.845
20%	0.879	0.888	0.914	0.828
30%	0.828	0.819	0.888	0.836
40%	0.853	0.828	0.914	0.802
50%	0.871	0.784	0.879	0.793





	DecisionTree	MLP	RandomForest	SVM
0%	0.912	0.842	0.857	0.872
10%	0.897	0.8	0.889	0.795
20%	0.909	0.868	0.919	0.784
30%	0.784	0.75	0.912	0.789
40%	0.833	0.756	0.943	0.75
50%	0.771	0.674	0.909	0.698




	DecisionTree	MLP	RandomForest	SVM
0%	0.756	0.78	0.732	0.829
10%	0.634	0.78	0.78	0.756
20%	0.732	0.805	0.829	0.707
30%	0.707	0.732	0.756	0.732
40%	0.732	0.756	0.805	0.659
50%	0.902	0.756	0.732	0.732


4.2.4.3 Confronto delle metriche per modello e livello di rumore







Andamento performance per SVM



Metriche per SVM per livello di outlier











4.2.4.4 Curve ROC per diversi livelli di outlier

Le curve ROC confermano le tendenze osservate:

- **Random Forest** mantiene AUC a 0.94–0.95 anche in presenza di molti outlier.
- **Decision Tree** passa da AUC 0.94 (0%) a 0.87 (50%), mostrando un calo moderato.
- **SVM** scende più nettamente da AUC 0.95 (0%) a 0.84 (50%).
- **MLP** evidenzia il crollo maggiore, con AUC che dal 0.93 cala fino a 0.78 al 50%.





4.2.4.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al feature noise tramite la metrica EPC:

Model	EPC
DecisionTree	-0.263
SVM	-0.925
RandomForest	0.366
MLP	-0.819

Interpretazione:

- **Random Forest (0.366)** è l'unico modello che ha mostrato **resilienza positiva**, riuscendo addirittura a trarre beneficio dalla presenza di outlier fino a certi livelli (20–40%). La natura dell'ensemble riduce l'impatto dei dati anomali, mantenendo stabilità nelle performance.
- **Decision Tree (-0.263)** mostra un calo moderato e non lineare: pur soffrendo gli outlier, conserva una certa adattabilità e in alcuni scenari mantiene un buon equilibrio tra recall e precision.
- **SVM (-0.925)** è risultato il modello più fragile: la sua sensibilità ai margini di separazione rende gli outlier particolarmente dannosi, con un degrado progressivo e costante delle metriche.
- **MLP (-0.819)** si colloca in una posizione intermedia: la rete neurale ha mostrato inizialmente una certa capacità di generalizzare, ma degrada rapidamente con l'aumentare degli outlier, soprattutto in termini di precisione.

In sintesi, gli esperimenti evidenziano come l'impatto degli outlier sia altamente dipendente dall'architettura del modello.

I metodi ensemble come Random Forest risultano i più robusti, mentre i modelli sensibili alle anomalie nei margini di decisione (SVM) o alla distribuzione dei dati (MLP) mostrano vulnerabilità marcate.

Le curve ROC e le metriche confermano questa tendenza: AUC rimane elevato per Random Forest, mentre cala significativamente per SVM e MLP con alti livelli di rumore anomalo.

4.2.5 Duplicates Features

La duplicazione di feature consiste nell'**aggiungere copie identiche di variabili** già presenti nel dataset. Questo tipo di contaminazione non introduce nuovi errori nei valori, ma **aumenta artificialmente la dimensionalità e la ridondanza informativa**.


In contesti clinici può emergere da errori di preprocessing, merge ripetuti o gestione scorretta delle variabili.


In questo esperimento sono state duplicate progressivamente alcune feature fino a raggiungere livelli del 10%, 20%, 30%, 40% e 50% del dataset, valutando come tale ridondanza influenzi le prestazioni dei modelli.

4.2.5.1 Matrici di confusione per diversi livelli di rumore

Le matrici di confusione mostrano i seguenti pattern:

- **Random Forest** mantiene una buona stabilità, mostrando solo variazioni minime nel bilanciamento tra falsi positivi e falsi negativi.
- **Decision Tree** è il più instabile: piccoli cambiamenti nei duplicati producono forti oscillazioni, in particolare nella classificazione dei diabetici.
- **SVM** e **MLP** restano complessivamente robusti, ma con fluttuazioni locali (es. SVM migliora a 30% duplicati, mentre MLP mostra recall crescente oltre il 40%).






4.2.5.2 Andamento delle performance al variare del livello di rumore


Dai grafici di **accuracy**, **precision**, **recall** e **F1-score** emergono le seguenti tendenze:

- **Random Forest** beneficia moderatamente della presenza di duplicati, in particolare nella precision, che cresce fino al 50%.
- **Decision Tree** soffre di instabilità, con cali pronunciati di precision al 30% e 40%.
- **SVM** mostra un comportamento non lineare: peggiora fino al 20%, ma ha un picco di performance al 30% (probabile effetto di supporti ridondanti nei margini).
- **MLP** appare sorprendentemente stabile: con più duplicati migliora soprattutto il recall, che cresce costantemente fino al 50%.




	DecisionTree	MLP	RandomForest	SVM
0%	0.888	0.871	0.862	0.897
10%	0.819	0.888	0.888	0.853
20%	0.862	0.853	0.879	0.862
30%	0.793	0.853	0.897	0.922
40%	0.819	0.905	0.888	0.879
50%	0.828	0.879	0.905	0.879

Precision vs Livello di Duplicazione




	DecisionTree	MLP	RandomForest	SVM
0%	0.912	0.842	0.857	0.872
10%	0.778	0.833	0.868	0.8
20%	0.778	0.816	0.886	0.821
30%	0.698	0.833	0.892	0.921
40%	0.717	0.875	0.912	0.865
50%	0.756	0.8	0.941	0.846

Recall vs Livello di Duplicazione




	DecisionTree	MLP	RandomForest	SVM
0%	0.756	0.78	0.732	0.829
10%	0.683	0.854	0.805	0.78
20%	0.854	0.756	0.756	0.78
30%	0.732	0.732	0.805	0.854
40%	0.805	0.854	0.756	0.78
50%	0.756	0.878	0.78	0.805




	DecisionTree	MLP	RandomForest	SVM
0%	0.827	0.81	0.789	0.85
10%	0.727	0.843	0.835	0.79
20%	0.814	0.785	0.816	0.8
30%	0.714	0.779	0.846	0.886
40%	0.759	0.864	0.827	0.821
50%	0.756	0.837	0.853	0.825


4.2.5.3 Confronto delle metriche per modello e livello di rumore




Metriche per DecisionTree per livello di duplicazione




Andamento performance con istanze duplicate - SVM






Metriche per SVM per livello di duplicazione



Andamento performance con istanze duplicate - RandomForest








4.2.5.4 Curve ROC per diversi livelli di duplicati


Le curve ROC confermano le tendenze osservate:

- Random Forest rimane stabile con AUC 0.95–0.96 in tutti i livelli di duplicazione.
- Decision Tree mostra un calo più evidente, con AUC che oscilla tra 0.94 (0%) e 0.89 (30%).
- SVM evidenzia alti e bassi: raggiunge AUC 0.95 a 0%, ma scende a 0.90–0.91 oltre il 40%.
- MLP mantiene performance competitive, con AUC compreso tra 0.93 e 0.95 ai bassi livelli, e solo un lieve calo al 50%.


Curva ROC con istanze duplicate - DecisionTree




Curva ROC con istanze duplicate - SVM



Curva ROC con istanze duplicate - RandomForest



Curva ROC con istanze duplicate - MLP



4.2.5.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al feature noise tramite la metrica EPC:

Model	EPC
DecisionTree	-0.579
SVM	0.112
RandomForest	0.838
MLP	0.251

Interpretazione:

- Random Forest (0.838) è risultato il modello più robusto: non solo non risente della ridondanza, ma in alcuni casi beneficia dei duplicati migliorando precision e stabilità.
- MLP (0.251) ha mostrato resilienza positiva, mantenendo buone prestazioni e un AUC stabile.
- SVM (0.112) evidenzia un comportamento neutro-positivo: pur subendo oscillazioni, resta mediamente robusto.
- Decision Tree (-0.579) è il più fragile: la ridondanza amplifica la sua tendenza all'overfitting e porta a un peggioramento netto delle performance.

In sintesi, i duplicati **non hanno un impatto devastante** come altre contaminazioni (es. label noise), ma **evidenziano** chiaramente **la superiorità dei metodi ensemble** (Random Forest) rispetto ai modelli più semplici e sensibili alla struttura dei dati.

4.3 Effetti degli errori combinati (Fase 2 – Parte II)

Dopo aver analizzato l'impatto dei singoli tipi di contaminazione, in questa sezione sono stati valutati scenari più complessi in cui due fonti di rumore vengono introdotte simultaneamente. Questa scelta riflette situazioni reali, dove gli errori nei dati raramente si presentano in forma isolata: un dataset clinico, ad esempio, può contenere contemporaneamente **etichette errate**, **valori mancanti**, **anomalie numeriche** o **duplicati**.

Per mantenere coerenza metodologica, la pipeline sperimentale è rimasta invariata rispetto alle fasi precedenti, includendo:

- preprocessing con imputazione e scaling,
- bilanciamento delle classi tramite SMOTE,
- addestramento dei modelli con iperparametri ottimizzati,
- valutazione mediante validazione incrociata stratificata,
- misurazione delle performance tramite accuracy, precision, recall, F1-score e AUC.

In questa fase sono state considerate quattro combinazioni principali di errori:

1. **Label Noise + Feature Noise**: simulazione di dataset con etichette errate e valori numerici perturbati.
2. **Label Noise + Missing Values**: etichette scorrette unite a feature con valori mancanti.
3. **Feature Noise + Feature Outliers**: presenza congiunta di rumore numerico diffuso e anomalie estreme.
4. **Duplicates Features + Feature Noise**: duplicazione di istanze congiunta a perturbazioni numeriche.

L'obiettivo è duplice:

1. **Valutare la robustezza dei modelli in scenari realistici e complessi**, dove gli errori interagiscono tra loro amplificando o mitigando gli effetti.
2. **Individuare i trade-off di ciascun algoritmo**, comprendendo quali siano maggiormente penalizzati dalla combinazione di contaminazioni e quali invece riescano a mantenere stabilità nelle prestazioni.

Questa analisi permette di evidenziare differenze sostanziali rispetto ai test con singoli errori, fornendo una visione più vicina all'utilizzo pratico dei modelli in ambito reale.

4.3.1 Label Noise + Feature Noise

La combinazione di rumore nelle etichette e rumore numerico nelle feature rappresenta uno degli scenari più critici per l'addestramento dei modelli.

Da un lato, etichette errate compromettono la funzione obiettivo del classificatore, inducendo apprendimento fuorviante; dall'altro, il disturbo nelle variabili numeriche riduce la separabilità tra le classi. L'effetto congiunto amplifica l'incertezza, simulando situazioni reali in cui errori di annotazione e misurazioni imprecise coesistono in dataset clinici.


Sono state generate combinazioni di rumore fino al 50% complessivo, sia in forma bilanciata (es. 25% feature + 25% label), sia in forma sbilanciata (es. 10% feature + 40% label, oppure 40% feature + 10% label).


L'obiettivo è confrontare le performance dei modelli sia sul totale degli errori, sia distinguendo il peso dei due tipi di contaminazione.

4.3.1.1 Matrici di confusione

Le matrici di confusione mostrano che:

- Il Label Noise ha un impatto molto più distruttivo (predizioni più sbilanciate, soprattutto errori su “Diabetico”).
- Il Feature Noise tende a ridurre la separabilità delle classi, ma in modo meno drastico.
- Quando entrambi i rumori sono presenti, gli effetti si combinano: in scenari 10% label + 40% feature si ottengono risultati diversi rispetto a 40% label + 10% feature, segnalando che non conta solo il totale, ma anche la natura dell'errore.






4.3.1.2 Andamento delle performance al variare del livello di rumore


Dopo aver tracciato accuratezza, precisione, recall e F1-score per ogni combinazione specifica, si osserva che:

- Tutti i modelli calano con l'aumento del rumore totale.
- L'MLP è quello che soffre di più quando aumenta il Label Noise.
- Il Random Forest è relativamente robusto al Feature Noise ma peggiora fortemente se il Label Noise è alto.
- La SVM e il Decision Tree mostrano andamenti intermedi.


Importante: 10% label + 40% feature $\neq$ 40% label + 10% feature, in quanto il tipo di rumore è determinante.




	DecisionTree	MLP	RandomForest	SVM
feature_0%_label_0%	0.888	0.871	0.862	0.897
feature_10%_label_10%	0.853	0.784	0.862	0.871
feature_10%_label_40%	0.741	0.655	0.716	0.767
feature_20%_label_20%	0.802	0.741	0.888	0.828
feature_20%_label_30%	0.759	0.638	0.81	0.802
feature_25%_label_25%	0.759	0.716	0.836	0.836
feature_30%_label_20%	0.793	0.759	0.897	0.819
feature_40%_label_10%	0.879	0.802	0.871	0.879



	DecisionTree	MLP	RandomForest	SVM
feature_0%_label_0%	0.912	0.842	0.857	0.872
feature_10%_label_10%	0.74	0.674	0.821	0.842
feature_10%_label_40%	0.762	0.509	0.577	0.625
feature_20%_label_20%	0.655	0.608	0.818	0.706
feature_20%_label_30%	0.618	0.49	0.721	0.714
feature_25%_label_25%	0.667	0.571	0.775	0.789
feature_30%_label_20%	0.689	0.623	0.822	0.692
feature_40%_label_10%	0.865	0.705	0.842	0.814







	DecisionTree	MLP	RandomForest	SVM
feature_0%_label_0%	0.756	0.78	0.732	0.829
feature_10%_label_10%	0.902	0.756	0.78	0.78
feature_10%_label_40%	0.39	0.659	0.732	0.854
feature_20%_label_20%	0.927	0.756	0.878	0.878
feature_20%_label_30%	0.829	0.61	0.756	0.732
feature_25%_label_25%	0.634	0.78	0.756	0.732
feature_30%_label_20%	0.756	0.805	0.902	0.878
feature_40%_label_10%	0.78	0.756	0.78	0.854




	DecisionTree	MLP	RandomForest	SVM
feature_0%_label_0%	0.827	0.81	0.789	0.85
feature_10%_label_10%	0.813	0.713	0.8	0.81
feature_10%_label_40%	0.516	0.574	0.645	0.722
feature_20%_label_20%	0.768	0.674	0.847	0.783
feature_20%_label_30%	0.708	0.543	0.738	0.723
feature_25%_label_25%	0.65	0.66	0.765	0.759
feature_30%_label_20%	0.721	0.702	0.86	0.774
feature_40%_label_10%	0.821	0.729	0.81	0.833

4.3.1.3 Confronto delle metriche per modello e livello di rumore








Andamento performance per combinazione - SVM



Metriche per combinazione - SVM









4.3.1.4 Curve ROC per diversi livelli di duplicati

Le curve ROC confermano le tendenze osservate:

- **Label noise è più dannoso**, poiché abbassa l'AUC in modo più netto.
- **Feature noise** degrada meno rapidamente le curve.
- Random Forest e SVM mantengono curve più vicine all'ideale anche in scenari sbilanciati.
- MLP collassa più velocemente, dato che AUC crolla sotto 0.7 già con combinazioni moderate.





4.3.1.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al feature noise tramite la metrica EPC:

Model	EPC_Total	EPC_Feature	EPC_Label
DecisionTree	-0.684	-0.069	-0.949
SVM	-0.680	-0.044	-0.969
RandomForest	-0.261	0.340	-0.729
MLP	-0.728	-0.130	-0.955

Interpretazione:

- EPC_Label è sempre molto negativo, cioè il label noise è il principale fattore di degrado.
- EPC_Feature è vicino a 0 (o addirittura positivo per Random Forest), quindi i modelli gestiscono bene il rumore nelle feature, a volte persino beneficiano leggermente di variabilità aggiunta.
- EPC_Total riassume la robustezza globale: Random Forest è il più stabile, MLP il più fragile.

In sintesi, l'esperimento ha mostrato che il **label noise** è la principale causa di degrado: peggiora recall e AUC molto più rapidamente rispetto al rumore sulle feature. Quest'ultimo ha un impatto più graduale e in alcuni casi limitato, specie per modelli ensemble come Random Forest.

Dai risultati, **Random Forest e SVM** si confermano i più robusti, mentre **MLP** è il più vulnerabile e degrada già a livelli moderati di rumore. Le matrici di confusione evidenziano che il label noise aumenta i falsi negativi, mentre il feature noise incide soprattutto sui falsi positivi.

L'EPC conferma queste osservazioni: la correlazione negativa è forte per il rumore nelle etichette, molto più debole per quello sulle feature. Nel complesso, emerge che in presenza di errori misti la stabilità dei modelli dipende soprattutto dalla gestione del label noise.

4.3.2 Label Noise + Missing Values


La co-presenza di **etichette errate** e **valori mancanti** è un caso realistico nei dataset clinici: la prima disturba direttamente la funzione obiettivo, la seconda introduce incertezza nelle feature (mitigata dall'imputazione).


Sono state generate combinazioni di rumore fino al 50% complessivo, sia in forma bilanciata (es. 25% feature + 25% label), sia in forma sbilanciata (es. 10% feature + 40% label, oppure 40% feature + 10% label).

4.3.2.1 Matrici di confusione

Le matrici di confusione mostrano che:

- Il Label Noise è dominante: aumenta soprattutto i falsi negativi (pazienti diabetici scambiati per sani), più evidente in MLP e Decision Tree quando la quota di label rumorose cresce.
- I Missing Values da soli sono meno distruttivi: con imputazione iterativa l'impatto resta moderato; l'effetto tipico è un leggero aumento dei falsi positivi.
- Quando entrambi i rumori sono presenti, gli effetti si combinano: in scenari 10% label + 40% feature si ottengono risultati diversi rispetto a 40% label + 10% feature, segnalando che non conta solo il totale, ma anche la natura dell'errore (il tipo di errore conta più del semplice totale).






4.3.2.3 Andamento delle performance al variare del livello di rumore


Dopo aver tracciato accuratezza, precisione, recall e F1-score per ogni combinazione specifica, si osserva che:

- Tutti i modelli peggiorano all'aumentare del rumore complessivo, ma con pendenze diverse.
- SVM e Random Forest sono i più stabili: reggono bene il missing (grazie a margini/ensemble) e degradano soprattutto quando cresce il Label Noise.
- Decision Tree mostra sensibilità intermedia: penalizzato dal label noise, tollera discretamente livelli moderati di missing.
- MLP è il più vulnerabile: con etichette sporche l'F1 e l'Accuracy calano rapidamente; il missing amplifica il problema se l'imputazione non ricostruisce bene le strutture informative.


Importante: 10% label + 40% feature $\neq$ 40% label + 10% feature, in quanto il tipo di rumore è determinante.




	DecisionTree	MLP	RandomForest	SVM
label 0% missing 0%	0.888	0.871	0.862	0.897
label 10% missing 10%	0.759	0.853	0.888	0.836
label 10% missing 40%	0.828	0.698	0.905	0.776
label 20% missing 20%	0.776	0.75	0.81	0.81
label 20% missing 30%	0.75	0.612	0.793	0.767
label 25% missing 25%	0.741	0.698	0.733	0.793
label 30% missing 20%	0.819	0.621	0.793	0.759
label 40% missing 10%	0.569	0.603	0.733	0.741



	DecisionTree	MLP	RandomForest	SVM
label 0% missing 0%	0.912	0.842	0.857	0.872
label 10% missing 10%	0.603	0.773	0.85	0.75
label 10% missing 40%	0.862	0.562	0.875	0.66
label 20% missing 20%	0.667	0.625	0.744	0.732
label 20% missing 30%	0.603	0.464	0.681	0.659
label 25% missing 25%	0.762	0.568	0.632	0.698
label 30% missing 20%	0.679	0.471	0.689	0.623
label 40% missing 10%	0.435	0.456	0.609	0.596







	DecisionTree	MLP	RandomForest	SVM
label 0% missing 0%	0.756	0.78	0.732	0.829
label 10% missing 10%	0.927	0.829	0.829	0.805
label 10% missing 40%	0.61	0.659	0.854	0.756
label 20% missing 20%	0.732	0.732	0.707	0.732
label 20% missing 30%	0.854	0.634	0.78	0.707
label 25% missing 25%	0.39	0.61	0.585	0.732
label 30% missing 20%	0.927	0.585	0.756	0.805
label 40% missing 10%	0.732	0.634	0.683	0.829







	DecisionTree	MLP	RandomForest	SVM
label 0% missing 0%	0.827	0.81	0.789	0.85
label 10% missing 10%	0.731	0.8	0.84	0.776
label 10% missing 40%	0.714	0.607	0.864	0.705
label 20% missing 20%	0.698	0.674	0.725	0.732
label 20% missing 30%	0.707	0.536	0.727	0.682
label 25% missing 25%	0.516	0.588	0.608	0.714
label 30% missing 20%	0.784	0.522	0.721	0.702
label 40% missing 10%	0.545	0.531	0.644	0.694

4.3.2.3 Confronto delle metriche per modello e livello di rumore













4.3.2.4 Curve ROC per diversi livelli di duplicati

Le curve ROC confermano le tendenze osservate:

- Label noise abbassa sensibilmente l'AUC, soprattutto per Decision Tree e MLP.
- I missing values da soli hanno un impatto più graduale, ma combinati con etichette sbagliate portano a un peggioramento netto.
- La Random Forest e la SVM mantengono le curve più vicine all'ideale anche con livelli moderati di errore (AUC > 0.8).
- L'MLP collassa rapidamente, con AUC che scende sotto 0.7 già a combinazioni 20% label + 30% missing.







4.3.2.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al feature noise tramite la metrica EPC:

Model	EPC_Total	EPC_Label	EPC_Missing
DecisionTree	-0.783	-0.785	0.067
SVM	-0.946	-0.831	-0.578
RandomForest	-0.522	0.833	-0.056
MLP	-0.898	-0.817	-0.520

Interpretazione:

- EPC_Label è sempre fortemente negativo: il label noise resta il principale fattore di degrado.
- EPC_Missing è vicino allo zero per Decision Tree e Random Forest, segnalando robustezza ai valori mancanti; è invece fortemente negativo per MLP e SVM, che soffrono maggiormente l'incompletezza dei dati.
- EPC_Total evidenzia che l'MLP è il più vulnerabile, seguito da SVM; Random Forest è più stabile, mentre Decision Tree mostra sensibilità intermedia.

In sintesi, il label noise rimane il fattore dominante nel peggioramento delle performance, ma la presenza di valori mancanti amplifica la fragilità dei modelli più sensibili (MLP e SVM). Random Forest si conferma il più robusto, mentre Decision Tree oscilla in base alla combinazione.

4.3.3 Feature Noise + Feature Outliers


La co-presenza di rumore sulle feature e di outlier è un caso rilevante in scenari clinici: il primo degrada la qualità dell'informazione in modo diffuso (valori perturbati), il secondo introduce osservazioni anomale che possono spostare i confini di decisione o confondere i classificatori.


Sono state generate combinazioni di rumore fino al 50% complessivo, sia in forma bilanciata (es. 25% feature + 25% label), sia in forma sbilanciata (es. 10% feature + 40% label, oppure 40% feature + 10% label).

4.3.3.1 Matrici di confusione

Le matrici di confusione mostrano che:

- Il Label Noise è dominante: aumenta soprattutto i falsi negativi (pazienti diabetici scambiati per sani), più evidente in MLP e Decision Tree quando la quota di label rumorose cresce.
- I Missing Values da soli sono meno distruttivi: con imputazione iterativa l'impatto resta moderato; l'effetto tipico è un leggero aumento dei falsi positivi.
- Quando entrambi i rumori sono presenti, gli effetti si combinano: in scenari 10% label + 40% feature si ottengono risultati diversi rispetto a 40% label + 10% feature, segnalando che non conta solo il totale, ma anche la natura dell'errore (il tipo di errore conta più del semplice totale).






4.3.3.3 Andamento delle performance al variare del livello di rumore


Dopo aver tracciato accuratezza, precisione, recall e F1-score per ogni combinazione specifica, si osserva che:

- Tutti i modelli **peggiorano** all'aumentare del rumore complessivo, ma con **pendenze diverse**.
- **SVM e Random Forest** sono i più **stabili**: reggono bene il missing (grazie a margini/ensemble) e degradano soprattutto quando cresce il Label Noise.
- **Decision Tree** mostra sensibilità intermedia: penalizzato dal label noise, tollera discretamente livelli moderati di missing.
- **MLP** è il più **vulnerabile**: con etichette sporche l'F1 e l'Accuracy calano rapidamente; il missing amplifica il problema se l'imputazione non ricostruisce bene le strutture informative.


Importante: 10% label + 40% feature $\neq$ 40% label + 10% feature, in quanto il tipo di rumore è determinante.




	DecisionTree	MLP	RandomForest	SVM
feature_0%_outlier_0%	0.888	0.871	0.862	0.897
feature_10%_outlier_10%	0.862	0.879	0.888	0.836
feature_10%_outlier_40%	0.819	0.836	0.905	0.802
feature_20%_outlier_20%	0.879	0.845	0.888	0.819
feature_20%_outlier_30%	0.819	0.836	0.897	0.828
feature_25%_outlier_25%	0.905	0.862	0.879	0.836
feature_30%_outlier_20%	0.871	0.888	0.905	0.819
feature_40%_outlier_10%	0.845	0.862	0.879	0.819



	DecisionTree	MLP	RandomForest	SVM
feature 0% outlier 0%	0.912	0.842	0.857	0.872
feature 10% outlier 10%	0.879	0.829	0.889	0.775
feature 10% outlier 40%	0.717	0.789	0.917	0.737
feature 20% outlier 20%	0.909	0.811	0.889	0.763
feature 20% outlier 30%	0.738	0.775	0.914	0.769
feature 25% outlier 25%	0.857	0.805	0.909	0.789
feature 30% outlier 20%	0.906	0.85	0.895	0.763
feature 40% outlier 10%	0.897	0.778	0.909	0.763







	DecisionTree	MLP	RandomForest	SVM
feature 0% outlier 0%	0.756	0.78	0.732	0.829
feature 10% outlier 10%	0.707	0.829	0.78	0.756
feature 10% outlier 40%	0.805	0.732	0.805	0.683
feature 20% outlier 20%	0.732	0.732	0.78	0.707
feature 20% outlier 30%	0.756	0.756	0.78	0.732
feature 25% outlier 25%	0.878	0.805	0.732	0.732
feature 30% outlier 20%	0.707	0.829	0.829	0.707
feature 40% outlier 10%	0.634	0.854	0.732	0.707







	DecisionTree	MLP	RandomForest	SVM
feature 0% outlier 0%	0.827	0.81	0.789	0.85
feature 10% outlier 10%	0.784	0.829	0.831	0.765
feature 10% outlier 40%	0.759	0.759	0.857	0.709
feature 20% outlier 20%	0.811	0.769	0.831	0.734
feature 20% outlier 30%	0.747	0.765	0.842	0.75
feature 25% outlier 25%	0.867	0.805	0.811	0.759
feature 30% outlier 20%	0.795	0.84	0.861	0.734
feature 40% outlier 10%	0.743	0.814	0.811	0.734

4.3.3.3 Confronto delle metriche per modello e livello di rumore













4.3.3.4 Curve ROC per diversi livelli di duplicati

Le curve ROC confermano le tendenze osservate:

- **Random Forest** mantiene AUC elevati (≥ 0.94) in quasi tutte le combinazioni, dimostrandosi molto robusta agli outlier.
- **Decision Tree** perde rapidamente area sotto la curva quando cresce la quota di outlier, scendendo a valori intorno a 0.84–0.86 nelle configurazioni più critiche.
- **SVM** resta sopra 0.90 per rumori moderati, ma degrada gradualmente fino a ~ 0.90 con outlier elevati.
- **MLP** mantiene AUC relativamente stabili (0.91–0.95), mostrando maggiore resilienza rispetto a quanto visto nel caso “Label Noise + Missing”.





4.3.3.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al feature noise tramite la metrica EPC:

Model	EPC_Total	EPC_Feature	EPC_Outlier
DecisionTree	-0.377	-0.048	0.513
SVM	-0.862	-0.557	-0.728
RandomForest	0.673	0.234	0.768
MLP	-0.379	0.094	-0.658

Interpretazione:

- Outlier sono il fattore più critico: EPC_Outlier è fortemente negativo per Decision Tree, SVM e MLP, segnalando forte degradazione della performance.
- Feature Noise è meno dannoso: EPC_Feature è vicino a 0 (Decision Tree), positivo per MLP e Random Forest.
- Random Forest emerge come unico modello con EPC positivi, cioè robusto sia a feature noise che ad outlier.
- SVM e MLP sono i più vulnerabili, con EPC_Total fortemente negativo; Decision Tree mostra una sensibilità intermedia, con particolare debolezza agli outlier.

In sintesi, gli outlier sulle feature risultano il fattore dominante nel peggioramento delle performance, mentre il semplice feature noise ha effetti più contenuti e talvolta trascurabili. La Random Forest si conferma il modello più robusto e stabile anche in scenari di forte contaminazione, mentre SVM e MLP mostrano una netta vulnerabilità agli outlier. Il Decision Tree si colloca in posizione intermedia, con prestazioni altalenanti a seconda della combinazione di rumori.

4.3.4 Duplicates Features + Feature Noise


La combinazione di **rumore nelle feature** e **duplicazione dei campioni** rappresenta un caso particolare: il primo degrada l'informazione introducendo variazioni casuali, mentre il secondo riduce la diversità del dataset, amplificando la ridondanza e rischiando di far “imparare a memoria” i modelli invece di generalizzare.


Sono state generate combinazioni di rumore fino al 50% complessivo, sia in forma bilanciata (es. 25% feature + 25% label), sia in forma sbilanciata (es. 10% feature + 40% label, oppure 40% feature + 10% label).

4.3.4.1 Matrici di confusione

Le matrici di confusione mostrano che:

- Feature Noise aumenta i falsi negativi, rendendo più difficile distinguere correttamente i pazienti diabetici.
- Duplicati hanno effetto più sottile: in modelli semplici come Decision Tree possono indurre overfitting, peggiorando la generalizzazione.
- Quando entrambi i rumori sono presenti, gli effetti si combinano: in scenari 10% label + 40% feature si ottengono risultati diversi rispetto a 40% label + 10% feature, segnalando che non conta solo il totale, ma anche la natura dell'errore (il tipo di errore conta più del semplice totale).






4.3.4.3 Andamento delle performance al variare del livello di rumore


Dopo aver tracciato accuratezza, precisione, recall e F1-score per ogni combinazione specifica, si osserva che:

- **Decision Tree:** andamento irregolare, con cali marcati di precisione e F1 già dal 40% di rumore; recall relativamente stabile ma oscillante.
- **MLP:** comportamento altalenante ma più resiliente rispetto al caso con outlier; al 50% recupera parzialmente, segnalando che i duplicati possono attenuare in parte l'effetto del rumore.
- **Random Forest:** mostra un trend quasi opposto agli altri: recall e F1 tendono a migliorare con l'aumento del rumore totale. L'ensemble neutralizza sia il feature noise che i duplicati, mantenendo stabilità.
- **SVM:** inizialmente stabile, ma peggiora a 40% di rumore, con cali su precision e recall; recupera solo parzialmente a 50%.


Importante: 10% label + 40% feature $\neq$ 40% label + 10% feature, in quanto il tipo di rumore è determinante.




	DecisionTree	MLP	RandomForest	SVM
feature_0%_dup_0%	0.888	0.871	0.862	0.897
feature_10%_dup_10%	0.888	0.879	0.871	0.888
feature_10%_dup_40%	0.879	0.871	0.888	0.897
feature_20%_dup_20%	0.845	0.819	0.879	0.853
feature_20%_dup_30%	0.871	0.897	0.888	0.914
feature_25%_dup_25%	0.879	0.879	0.862	0.862
feature_30%_dup_20%	0.871	0.897	0.862	0.845
feature_40%_dup_10%	0.828	0.871	0.862	0.853



	DecisionTree	MLP	RandomForest	SVM
feature_0%_dup_0%	0.912	0.842	0.857	0.872
feature_10%_dup_10%	0.912	0.846	0.861	0.833
feature_10%_dup_40%	0.886	0.842	0.889	0.914
feature_20%_dup_20%	0.767	0.75	0.865	0.8
feature_20%_dup_30%	0.842	0.872	0.889	0.919
feature_25%_dup_25%	0.886	0.829	0.821	0.821
feature_30%_dup_20%	0.81	0.854	0.821	0.78
feature_40%_dup_10%	0.769	0.81	0.821	0.786







	DecisionTree	MLP	RandomForest	SVM
feature 0% dup 0%	0.756	0.78	0.732	0.829
feature 10% dup 10%	0.756	0.805	0.756	0.854
feature 10% dup 40%	0.756	0.78	0.78	0.78
feature 20% dup 20%	0.805	0.732	0.78	0.78
feature 20% dup 30%	0.78	0.829	0.78	0.829
feature 25% dup 25%	0.756	0.829	0.78	0.78
feature 30% dup 20%	0.829	0.854	0.78	0.78
feature 40% dup 10%	0.732	0.829	0.78	0.805







	DecisionTree	MLP	RandomForest	SVM
feature 0% dup 0%	0.827	0.81	0.789	0.85
feature 10% dup 10%	0.827	0.825	0.805	0.843
feature 10% dup 40%	0.816	0.81	0.831	0.842
feature 20% dup 20%	0.786	0.741	0.821	0.79
feature 20% dup 30%	0.81	0.85	0.831	0.872
feature 25% dup 25%	0.816	0.829	0.8	0.8
feature 30% dup 20%	0.819	0.854	0.8	0.78
feature 40% dup 10%	0.75	0.819	0.8	0.795

4.3.4.3 Confronto delle metriche per modello e livello di rumore













4.3.4.4 Curve ROC per diversi livelli di duplicati

Le curve ROC confermano le tendenze osservate:





4.3.4.5 Riepilogo dei risultati

La seguente tabella riassume la sensibilità dei modelli al feature noise tramite la metrica EPC:

Model	EPC_Total	EPC_Feature	EPC_Dub
DecisionTree	-0.464	-0.753	0.062
SVM	-0.341	-0.690	0.183
RandomForest	0.286	-0.286	0.712
MLP	0.141	0.105	0.105

Interpretazione:

- Feature Noise è il fattore più critico: EPC_Feature è fortemente negativo per Decision Tree e SVM, moderato per Random Forest e vicino a zero/positivo per MLP.
- Duplicati hanno effetto minore: EPC_Dup è positivo per MLP, Random Forest e SVM, segnalando che la semplice ridondanza è gestibile.
- Random Forest è l'unico modello che beneficia chiaramente dei duplicati (EPC_Dup = 0.712), sfruttandoli in modo positivo.
- Decision Tree mostra la peggior sensibilità al feature noise, con EPC_Total negativo.
- MLP sorprende con EPC_Total positivo: i duplicati sembrano bilanciare l'effetto del rumore numerico.

In sintesi, Il feature noise rimane il principale fattore di degrado, mentre i duplicati hanno un impatto contenuto e in alcuni casi persino compensatorio (MLP, Random Forest).

- Random Forest si conferma il modello più robusto e capace di sfruttare la ridondanza.
- MLP mostra resilienza inattesa, mantenendo EPC totale positivo.
- SVM e Decision Tree restano vulnerabili al rumore sulle feature, con Decision Tree particolarmente penalizzato.

4.4 Robustezza dei modelli

Per sintetizzare i risultati emersi dalle diverse analisi, la tabella seguente riassume il comportamento dei modelli nei confronti delle singole tipologie di errore introdotte.

Errore singolo	Decision Tree	Random Forest	SVM	MLP
Label Noise	Degrada molto	Degrada, ma meno degli altri	Sensibile	Molto vulnerabile
Feature Noise	Impatto limitato	Talvolta positivo	Resistente	Talvolta positivo (regolarizzazione leggera)
Missing Values	Vulnerabile se l'imputazione fallisce	Molto stabile (grazie al bagging)	Stabile solo con livelli bassi	Soffre molto (dipendenza forte da completezza)
Outlier	Moderata resistenza	Molto robusto	Sensibile (margine spostato)	Molto vulnerabile
Duplicati	Rischio overfitting	Può migliorare stabilità	Neutrale	A volte positivo (rafforza pattern durante l'addestramento)

Dopo l'analisi dei singoli tipi di contaminazione, sono stati considerati anche scenari in cui **due tipi di errore coesistono nello stesso dataset**. Queste situazioni sono particolarmente rilevanti in ambito reale, dove difficilmente i dati presentano un solo tipo di imperfezione.

L'obiettivo era valutare se gli effetti dei diversi errori si **sommassero linearmente** oppure se uno dei due diventasse **dominante**, riducendo l'impatto dell'altro.

I quattro casi testati mostrano dinamiche differenti: in alcuni scenari (es. *Label Noise* + *Missing Values*) domina un singolo errore, mentre in altri (es. *Feature Noise* + *Outlier*) gli effetti si combinano e amplificano il degrado.

Errore combinato	Decision Tree	Random Forest	SVM	MLP
Label Noise + Feature Noise	Molto penalizzato (label noise dominante)	Regressione moderata, resta stabile grazie al bagging	Sensibile al label noise, degrado evidente	Collasso rapido: backpropagation amplifica etichette sbagliate

Label Noise + Missing Values	Vulnerabile: se imputazione fallisce degrada velocemente	Abbastanza stabile (solo label noise degrada)	Resiste a missing bassi, ma peggiora con label noise	Estremamente vulnerabile: somma di due debolezze (label + missing)
Feature Noise + Outlier	Sensibilità intermedia: outlier influenzano split, ma non il semplice feature noise	Molto robusto: AUC resta alto anche con forti outlier	Vulnerabile: outlier spostano margine, degrado progressivo	Molto vulnerabile: outlier e rumore numerico amplificano l'instabilità
Duplicati + Feature Noise	Rischio di overfitting accentuato dai duplicati	Stabile o leggermente positivo (bagging beneficia di campioni ripetuti)	Quasi neutrale: duplicati non incidono, gestisce bene rumore moderato	A volte positivo (rafforza pattern), ma rischio di overfitting se rumore è alto

In sintesi, l'analisi ha evidenziato che:

- **Gli errori non hanno lo stesso peso:** il Label Noise rimane il più distruttivo, mentre Feature Noise e Duplicati in alcuni casi hanno persino effetti neutri o lievemente positivi.
- **Le combinazioni di errori possono avere esiti diversi:** talvolta domina un singolo fattore (es. Label Noise), altre volte gli effetti si amplificano reciprocamente (es. Feature Noise + Outlier).
- **La robustezza dipende fortemente dalla natura del modello:** Random Forest si conferma il più stabile in quasi tutti gli scenari, mentre SVM e Decision Tree occupano una posizione intermedia, con punti di forza e debolezze specifici. MLP è risultato il più fragile, soprattutto quando gli errori toccano le etichette o introducono variabilità estrema nei dati.

Questi risultati mettono in evidenza l'importanza di **conoscere il contesto dei dati e il tipo di errori presenti**, perché la scelta del modello non può prescindere dalla qualità del dataset.

Per completezza, la tabella sotto riporta i valori di **Error-Performance Correlation** per ciascun modello e scenario considerato.

Scenario	Decision Tree	SVM	Random Forest	MLP
Label Noise	-0.923	-0.941	-0.888	-0.989
Feature Noise	-0.505	0.639	0.655	0.218
Missing Values	-0.974	-0.901	-0.696	-0.845
Outliers	-0.263	-0.925	0.366	-0.819
Duplicates	-0.579	0.112	0.838	0.251
Label + Feature Noise	-0.684 (total) -0.069 (Feature) -0.949 (Label)	-0.680 (total) -0.044 (Feature) -0.969 (Label)	-0.261 (total) 0.340 (Feature) -0.729 (Label)	-0.728 (total) -0.130 (Feature) -0.955 (Label)
Label + Missing Values	-0.783 (total) -0.785 (Label) 0.067 (Missing)	-0.946 (total) -0.831 (Label) -0.578 (Missing)	-0.522 (total) 0.833 (Label) -0.056 (Missing)	-0.898 (total) -0.817 (Label) -0.520 (Missing)
Feature + Outliers	-0.377 (total) -0.048 (Feature) 0.513 (Outlier)	-0.862 (total) -0.557 (Feature) -0.728 (Outlier)	0.673 (total) 0.234 (Feature) 0.768 (Outlier)	-0.379 (total) 0.094 (Feature) -0.658 (Outlier)

Feature + Duplicates	-0.464 (total) -0.044 (Feature) -0.497 (Duplicates)	-0.341 (total) 0.058 (Feature) -0.401 (Duplicates)	0.286 (total) 0.132 (Feature) 0.281 (Duplicates)	0.141 (total) 0.048 (Feature), 0.161 (Duplicates)
---------------------------------	--	---	--	---

5. Conclusioni

L'analisi ha mostrato chiaramente che **non tutti gli errori hanno lo stesso impatto** sulle performance dei modelli di Machine Learning.

- **Label Noise** è emerso come il fattore più critico: anche basse percentuali compromettono fortemente l'apprendimento, con effetti particolarmente distruttivi su MLP e SVM.
- **Feature Noise** ha avuto un impatto molto più limitato, in alcuni casi persino positivo (leggero effetto regolarizzante per Random Forest e MLP).
- **Missing Values** penalizzano soprattutto MLP e Decision Tree, mentre Random Forest mantiene stabilità fino a percentuali elevate.
- **Outlier** colpiscono duramente SVM e MLP, mentre Random Forest mostra una notevole capacità di assorbire l'effetto anomalo.
- **Duplicati** si sono rivelati meno dannosi: spesso i modelli ensemble e MLP ne hanno beneficiato o sono rimasti stabili, mentre il Decision Tree ha mostrato fragilità per overfitting.

Negli scenari di **errori combinati**, si conferma che il **Label Noise resta dominante**, amplificando la degradazione anche in presenza di altre contaminazioni.

I modelli più sensibili (MLP, SVM) collassano già a livelli moderati di rumore, mentre la Random Forest emerge come il modello più **robusto e costante**, con Decision Tree che occupa una posizione intermedia e oscillante.

In sintesi, la gerarchia di robustezza osservata è:

Random Forest > SVM $\approx$ Decision Tree > MLP.

5.1 Natura dei modelli

I risultati sperimentali riflettono la natura intrinseca dei modelli:

La **Random Forest** si conferma il modello **più robusto** perché sfrutta un approccio **ensemble bagging**: molteplici alberi, addestrati su campioni diversi del dataset e con sottoinsiemi di feature, riducono la varianza e diluiscono l'effetto di rumori locali o di outlier. Anche in presenza di etichette errate o feature perturbate, l'aggregazione delle predizioni mitiga l'impatto di singoli errori, spiegando gli EPC positivi o prossimi allo zero per feature noise e duplicati.

La **Support Vector Machine (SVM)** è progettata per massimizzare i margini tra le classi e quindi mostra una buona resistenza a rumore moderato nelle feature: piccoli errori non alterano significativamente l'iperpiano di separazione. Tuttavia, la SVM è più vulnerabile al **label noise** (perché punti mal etichettati possono diventare support vector influenti) e agli **outlier** (che possono spostare il margine). Questo spiega perché la sua robustezza è intermedia e peggiora soprattutto quando il rumore coinvolge le etichette.

Il **Decision Tree** è molto sensibile al **label noise** perché ogni split viene scelto per massimizzare l'informazione basata sui dati disponibili: etichette errate portano a regole sbagliate e generalizzazione debole. Tuttavia, rispetto alla SVM, il Decision Tree è meno influenzato da **outlier numerici**, dato che costruisce soglie discrete sui valori delle feature: l'impatto di valori estremi resta circoscritto. Per questo motivo si colloca su un livello simile alla SVM ma con punti di forza e debolezza diversi.

Infine, **Multilayer Perceptron (MLP)** è il modello più vulnerabile, soprattutto al **label noise**: il processo di backpropagation propaga errori sistematicamente, "imparando" da etichette sbagliate. Inoltre, essendo un modello parametrico con molti gradi di libertà, il MLP è incline all'**overfitting** in presenza di rumore o dati duplicati, e la sua stabilità dipende fortemente dalla qualità e dalla quantità dei dati. Sebbene in alcuni casi il rumore numerico possa avere un effetto regolarizzante, in generale la rete degrada più rapidamente rispetto agli altri modelli.

Modello	Punti di forza osservati	Debolezze principali osservate
Random Forest	• Elevata robustezza complessiva (EPC talvolta positivo). • Gestisce bene feature noise e duplicati grazie al bagging. • Curve ROC restano alte (>0.9) anche con outlier.	• Più vulnerabile al label noise (falsi negativi in aumento). • Con etichette molto sporche la performance degrada comunque.
SVM	• Buona stabilità con feature noise (marginari regolari). • ROC > 0.8 in molti scenari. • Regressione graduale in caso di rumore moderato.	• Sensibile a label noise (support vector mal etichettati influenzano il margine). • Vulnerabile ad outlier estremi.
Decision Tree	• Abbastanza resistente a feature noise (split discreti). • Degrada meno di MLP con outlier moderati.	• Molto sensibile al label noise (regole di split sbagliate). • Performance instabile: peggiora rapidamente con rumori combinati.

MLP	• In alcuni casi tollera meglio feature noise (leggera variabilità utile come regolarizzazione).	• Il più vulnerabile in assoluto. • Sensibile al label noise (propaga errori in backpropagation). • Soffre missing values e outlier. • Tendenza all'overfitting con dati duplicati.
------------	--	--

In conclusione, l'analisi ha evidenziato come la robustezza dei modelli dipenda fortemente dalla loro natura e dal tipo di contaminazione presente nei dati.

Gli errori di etichetta si confermano il fattore più critico, mentre il rumore numerico e i duplicati hanno effetti più contenuti. Random Forest emerge come il modello più stabile e affidabile in scenari clinici realistici, mentre l'MLP risulta il più fragile e sensibile alla qualità dei dati.

Questa gerarchia di robustezza fornisce indicazioni pratiche sulla scelta del modello e sulla qualità minima dei dati necessaria per garantire predizioni affidabili.